

Chapitre 6 : Estimation (Partie 1)

L'estimation est le processus qui consiste à déduire les valeurs des paramètres inconnus d'une population à partir des données observées sur un échantillon. Ce chapitre pose les bases théoriques de cette démarche.

0.1 Rappels sur les Lois Fondamentales (6.1)

Ces distributions sont les outils de base pour les tests statistiques et les intervalles de confiance. Elles dérivent toutes de la loi Normale.

0.1.1 Loi du Khi-deux (χ^2)

Définition : Loi du χ^2

Soient $U_1, \dots, U_n$ des variables aléatoires indépendantes suivant la loi normale centrée réduite $\mathcal{N}(0, 1)$. La variable somme des carrés suit une loi du Khi-deux à n degrés de liberté :

$$X = \sum_{i=1}^n U_i^2 \sim \chi_n^2$$

Moments :

- Espérance : $E(X) = n$
- Variance : $V(X) = 2n$

0.1.2 Loi de Fisher-Snedecor (F)

Elle est fondamentale pour l'analyse de la variance (ANOVA) et la comparaison de variances.

Définition : Loi de Fisher

Soient deux variables indépendantes $X \sim \chi_n^2$ et $Y \sim \chi_p^2$. Le rapport normalisé suit une loi de Fisher à (n, p) degrés de liberté :

$$F = \frac{X/n}{Y/p} \sim \mathcal{F}(n, p)$$

0.1.3 Loi de Student (t)

C'est la loi utilisée pour l'estimation de la moyenne quand la variance est inconnue.

Définition : Loi de Student

Soit $U \sim \mathcal{N}(0, 1)$ et $X \sim \chi_n^2$ indépendantes. La variable T suit une loi de Student à n degrés de liberté :

$$T = \frac{U}{\sqrt{X/n}} \sim t_n$$

Note : Pour $n \geq 30$, la loi de Student converge vers la loi Normale $\mathcal{N}(0, 1)$.

0.1.4 Cas des Échantillons Gaussiens

Théorème : Théorème de Cochran

Si un échantillon $(X_1, \dots, X_n)$ est issu d'une loi normale $\mathcal{N}(\mu, \sigma^2)$, alors :

1. La moyenne empirique $\bar{X}$ et la variance empirique S^2 sont **indépendantes**.
2. La variance empirique suit (à un facteur près) une loi du Khi-deux :

$$\frac{nS^2}{\sigma^2} \sim \chi_{n-1}^2$$

0.2 Échantillonnage (6.2)

0.2.1 Terminologie et Méthodes

L'objectif est de constituer un échantillon représentatif.

- **Méthodes Probabilistes (Aléatoires) :** Tirage au sort, Stratifié, Grappes. Chaque élément a une probabilité connue d'être choisi. Condition nécessaire pour appliquer la théorie statistique.
- **Méthodes Non-probabilistes (Empiriques) :** Quotas, Convenance. Utilisées quand la base de sondage est inexistante, mais les marges d'erreur sont inconnues.

0.2.2 L'Échantillon Aléatoire et Statistiques

Définition : Échantillon Aléatoire

Un échantillon aléatoire de taille n est un vecteur $(X_1, \dots, X_n)$ de n variables aléatoires indépendantes et de même loi (i.i.d.) que la variable parente X .

Une **statistique** est une fonction de l'échantillon (ex : moyenne, variance) qui ne dépend pas de paramètres inconnus. C'est une variable aléatoire.

0.2.3 Distributions Échantillonnales

Soit une population de moyenne μ et de variance σ^2 .

1. La Moyenne Empirique $\bar{X}_n$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- $E(\bar{X}_n) = \mu$ (Estimateur sans biais).
- $V(\bar{X}_n) = \frac{\sigma^2}{n}$ (La précision augmente avec n).

2. La Variance Empirique S_n^2 (Biaisée)

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

- $E(S_n^2) = \frac{n-1}{n} \sigma^2$.
- **Biais** : $E(S_n^2) - \sigma^2 = -\frac{\sigma^2}{n} \neq 0$. Elle sous-estime la vraie variance.

3. La Variance Corrigée S_{nc}^2 (Sans Biais)

Pour annuler le biais, on divise par $n - 1$ (degrés de liberté) :

$$S_{nc}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- $E(S_{nc}^2) = \sigma^2$. C'est l'estimateur à utiliser en pratique.

0.3 Propriétés des Estimateurs

Un estimateur $\hat{\theta}$ est une "recette" pour deviner un paramètre θ .

0.3.1 Qualités d'un estimateur

Propriétés

- **Sans Biais** : Si $E(\hat{\theta}) = \theta$.
- **Erreur Quadratique Moyenne (EQM)** : $EQM(\hat{\theta}) = V(\hat{\theta}) + (\text{Biais})^2$.
C'est le critère principal de comparaison.
- **Convergent** : Si $\hat{\theta}_n \xrightarrow{P} \theta$ quand $n \rightarrow \infty$.

0.3.2 Borne de Cramer-Rao et Efficacité

Il existe une limite absolue à la précision d'un estimateur sans biais.

Théorème : Inégalité de Cramer-Rao

Pour tout estimateur $\hat{\theta}$ sans biais, la variance est minorée par l'inverse de l'Information de Fisher $I_n(\theta)$:

$$V(\hat{\theta}) \geq \frac{1}{I_n(\theta)}$$

Un estimateur qui atteint cette borne (variance minimale possible) est qualifié d'**efficace**.